


Missing Data Imputation Report

1. Introducción

Este informe detalla un análisis exhaustivo de las técnicas de imputación de datos faltantes aplicadas a un conjunto de datos simulado de calificaciones de estudiantes. Comparamos los métodos de imputación por media, mediana, regresión y hot-deck (relleno hacia adelante y relleno hacia atrás), visualizando su impacto en las distribuciones de datos.

2. Visualización inicial de datos faltantes



El mapa de calor anterior representa visualmente la distribución de los valores faltantes (en morado/amarillo) en las columnas de asignaturas del DataFrame original. Esto proporciona una comprensión inicial de la dispersión de los datos antes de la imputación.


3. Impacto de las técnicas de imputación en las distribuciones de datos

Los siguientes histogramas ilustran las distribuciones de calificaciones para cada asignatura después de aplicar varias técnicas de imputación, en comparación con la distribución original.

Missing Data Imputation Report

3.1 Comparación de distribución para las calificaciones de Math


Comparación de distribución para las calificaciones de Math



Missing Data Imputation Report

3.2 Comparación de distribución para las calificaciones de Science


Comparación de distribución para las calificaciones de Science



Missing Data Imputation Report

3.3 Comparación de distribución para las calificaciones de History


Comparación de distribución para las calificaciones de History



Missing Data Imputation Report

3.4 Comparación de distribución para las calificaciones de Art


Comparación de distribución para las calificaciones de Art



Missing Data Imputation Report

3.5 Comparación de distribución para las calificaciones de English

Comparación de distribución para las calificaciones de English



Missing Data Imputation Report

4. Preguntas de análisis y conclusiones clave

Preguntas de análisis

1. Si un estudiante tenía una nota faltante, ¿es justo reemplazarla con la media o mediana de otros?

* Respuesta: Reemplazar con la media o mediana puede no ser 'justo' en un sentido individual, ya que ignora el rendimiento específico del estudiante. Sin embargo, puede ser una aproximación estadística válida para mantener la coherencia del conjunto de datos y evitar la pérdida de información de otros registros. La 'justicia' dependerá del objetivo del análisis.

2. Cuando usamos regresión para predecir valores faltantes, estamos asumiendo que una variable puede explicar a otra. ¿Crees que siempre es válido hacer esa suposición? ¿Qué limitaciones o riesgos podrían presentarse si en realidad no existe una relación fuerte entre las variables?

* Respuesta: No siempre es válido. La suposición es válida solo si existe una correlación significativa entre las variables. Si no hay una relación fuerte, la regresión puede generar valores imprecisos o incluso distorsionar el conjunto de datos, creando relaciones espurias o subestimando la variabilidad real. Esto puede llevar a conclusiones erróneas en análisis posteriores.

3. ¿Qué pasaría si, después de imputar, un estudiante aprueba o reprueba gracias a la técnica usada?

* Respuesta: Esto resalta un riesgo crítico de la imputación. Si la imputación altera el estado de aprobación/reprobación, puede tener consecuencias significativas e injustas para el estudiante. Es crucial considerar el impacto de la imputación en métricas clave y decisiones basadas en los datos.

4. ¿Qué método sería más adecuado para este caso y por qué? Tener como base la gráfica de comparación

* Respuesta: Basado en las gráficas, un método que conserve la forma de la distribución original sin introducir picos artificiales o sesgos significativos sería preferible. Por ejemplo, si la regresión muestra una distribución que se alinea mejor con la original sin una concentración excesiva en un solo punto, podría ser más adecuada que la media o mediana. La elección también depende de la naturaleza de los datos y el contexto específico.

5. ¿Qué mensaje deja este ejercicio sobre la importancia de manejar valores nulos antes de aplicar los modelos machine learning?

* Respuesta: Este ejercicio subraya la importancia crítica de manejar los valores nulos con cuidado. Una imputación inadecuada puede alterar fundamentalmente las distribuciones de datos, introducir sesgos, reducir la varianza y llevar a modelos de Machine Learning con rendimientos sesgados o conclusiones erróneas. Es esencial seleccionar una técnica de imputación que sea apropiada para el tipo de datos y el problema específico, y siempre evaluar su impacto.

Missing Data Imputation Report

Pregunta de reflexion

¿Por qué crees que la capacidad de predecir resultados a partir de datos es valiosa para una organización o institución?

* Respuesta: Este análisis demuestra que la capacidad de predecir resultados a partir de datos no es solo un ejercicio técnico, sino una herramienta estratégica de alto valor institucional. Como se observa en el ejercicio de imputación por regresión, cuando existe una correlación real entre variables, la predicción permite mantener la coherencia del conjunto de datos y evitar la pérdida de información crítica.

Sin embargo, el valor real de esta capacidad radica en la responsabilidad técnica: una organización que predice correctamente protege la integridad de sus métricas y asegura que decisiones vitales --como la aprobación o reprobación de un estudiante-- no se vean alteradas por sesgos o picos artificiales en los datos. En última instancia, manejar valores nulos con rigor científico es lo que garantiza que los modelos de Machine Learning institucionales entreguen conclusiones justas, precisas y libres de distorsiones estadísticas.